

## GUION CRONOMETRADO

# Generación de escenarios BTC-ETH para stress testing

Guion oral para una presentación de 5 minutos

### Higinio

0:00-1:35

Presentación del problema y  
Block Bootstrap condicionado

### Hugo

1:35-3:05

Normalizing Flow y  
Conditional GAN

### Javier

3:05-5:00

CVAE condicionado y  
conclusión

Ritmo recomendado: 125-135 palabras por minuto. Priorizar una idea central por diapositiva y evitar leer todas las cifras.

## DIAPOSITIVA 1

### Presentación

0:00-0:12

Buenos días. Somos Javier Chulvi, Hugo Vinuesa e Higinio Paterna. Nuestro trabajo estudia cómo generar escenarios conjuntos de Bitcoin y Ethereum que puedan utilizarse en pruebas de estrés financiero.

## DIAPOSITIVA 2

### Problema y justificación

0:12-0:50

El problema es que los episodios extremos son escasos en los datos históricos y, además, la relación entre Bitcoin y Ethereum cambia precisamente durante las crisis.

Por eso queremos generar múltiples futuros plausibles. Partimos de contextos de 60 días, descritos mediante 14 señales, y generamos 30 días futuros para ambos activos.

Comparamos un baseline y tres modelos neuronales. Después evaluamos los escenarios mediante métricas de fidelidad, riesgo -como VaR, Expected Shortfall y drawdown- y utilidad predictiva sobre una cartera compuesta por un 60 % de Bitcoin y un 40 % de Ethereum.

La pregunta central es si añadir datos sintéticos mejora realmente una tarea posterior.

*Apoyo visual: recorrer de izquierda a derecha el flujo de la diapositiva.*

## DIAPOSITIVA 3

### Block Bootstrap condicionado

0:50-1:35

Nuestro punto de referencia es un Block Bootstrap condicionado. Es un método no paramétrico: busca contextos históricos similares y remuestrea bloques temporales, conservando la relación conjunta entre Bitcoin y Ethereum.

Utilizando exclusivamente validación, seleccionamos bloques de 12 pasos -equivalentes a tres días- y 128 vecinos.

El resultado es muy competitivo: obtiene la mejor fidelidad marginal, el menor error de correlación en estrés y el menor error de dependencia de cola.

Sin embargo, aparece el primer resultado importante del trabajo: al añadir un 25 % de datos sintéticos, el error downstream aumenta del 7,955 al 8,468 %. Por tanto, preservar bien la distribución y los extremos no garantiza mejorar la predicción.

A continuación, Hugo presenta los dos modelos con resultados más contrastantes.

*Transición: mirar a Hugo al decir la última frase.*

## DIAPOSITIVA 4

## Normalizing Flow

1:35-2:18

El primer modelo neuronal es un Normalizing Flow condicionado. Su principal ventaja es que aprende una densidad explícita, por lo que podemos asignar probabilidades a los escenarios y analizar sus colas.

En la gráfica vemos que la pérdida de validación empieza a empeorar muy pronto. Por eso seleccionamos el checkpoint de la época 5, antes de que aparezca un sobreajuste claro.

El Flow consigue los mejores resultados en persistencia de la volatilidad, maximum drawdown y cobertura de VaR al 95 y al 99 %.

En downstream, validación no justifica añadir datos sintéticos. Aunque con un 100 % adicional el test mejora un 4,3 %, lo consideramos únicamente descriptivo, porque esa mejora no estaba respaldada por validación.

*Apoyo visual: señalar el mínimo temprano de validación y después las cuatro tarjetas de métricas.*

## DIAPOSITIVA 5

## Conditional GAN

2:18-3:05

La Conditional GAN utiliza un generador y un discriminador que compiten durante el entrenamiento. La escogimos para contrastar este aprendizaje adversarial con los enfoques probabilísticos.

Aunque las distribuciones marginales parecen visualmente similares, el discriminador externo separa perfectamente los datos reales de los sintéticos. Además, la GAN presenta el peor error de correlación durante situaciones de estrés.

Sin embargo, obtiene la mejor cobertura de la distribución de referencia y, al añadir un 100 % de datos sintéticos, alcanza un error de test del 7,052 %, una mejora descriptiva del 11,4 %.

Esta aparente contradicción resume una de las ideas principales del trabajo: fidelidad generativa y utilidad downstream no son lo mismo.

Javier continúa con el CVAE y la comparación final.

*Transición: hacer una pausa breve después de 'no son lo mismo'.*

## DIAPOSITIVA 6

## CVAE condicionado

3:05-3:48

El CVAE modela múltiples futuros posibles mediante un espacio latente probabilístico condicionado por el contexto reciente.

Se entrenó durante 18 épocas, aplicando early stopping con la pérdida de validación y sin utilizar el conjunto de test para seleccionar el modelo.

Es el modelo neuronal más equilibrado. Obtiene el mejor resultado entre las redes frente al discriminador externo y lidera tanto en distancia entre regímenes como en volatilidad realizada.

Además, añadir un 25 % de datos sintéticos reduce ligeramente el error de test, del 7,955 al 7,770 %.

Por tanto, no domina todas las métricas, pero es el generador neuronal cuyos escenarios resultan más difíciles de distinguir de los datos reales.

*Apoyo visual: destacar primero el 74,5 % y después las dos métricas en las que ocupa el primer puesto.*

La conclusión es que no existe un ganador global.

El Bootstrap es especialmente sólido preservando dependencia y colas. El CVAE destaca en regímenes y realismo. El Flow reproduce mejor determinadas propiedades temporales y métricas de riesgo, como VaR y drawdown. Finalmente, la GAN presenta problemas claros de fidelidad conjunta, pero también la señal downstream más favorable.

Tanto la matriz de rankings como las curvas de la derecha muestran que la posición de cada modelo cambia según la dimensión evaluada y según la cantidad de datos sintéticos añadidos.

Por ello, el mejor generador depende del objetivo financiero concreto. Para stress testing, por ejemplo, puede ser preferible el Bootstrap; para generar escenarios más realistas y equilibrados, el CVAE; y para algunas métricas específicas de riesgo, el Flow.

Nuestra conclusión principal es que los modelos generativos deben compararse separando tres dimensiones: fidelidad estadística, representación del riesgo y utilidad predictiva. Resumirlas en una única puntuación ocultaría trade-offs relevantes.

En definitiva, los datos sintéticos pueden aportar valor, pero ese valor debe demostrarse mediante validación y no asumirse únicamente porque los escenarios parezcan realistas.

Muchas gracias.

*Cierre: terminar mirando al público, no a la pantalla.*