


Generación de escenarios BTC–ETH para stress testing

Javier Chulvi · Hugo Vinuesa · Higinio Paterna

Generación de escenarios BTC–ETH para stress testing


Los episodios extremos son escasos y la relación BTC–ETH cambia en crisis:
necesitamos múltiples futuros plausibles.



● Justificación: ampliar escenarios de estrés y comprobar si mejoran la utilidad downstream.

Block Bootstrap condicionado

Baseline no paramétrico: mide si las redes superan el remuestreo de bloques temporales.



SELECCIÓN EN VALIDACIÓN

12 pasos (3 días) · 128 vecinos

0,106

W1 marginal medio

#1 de los cuatro

0,038

error corr. en estrés

#1

0,039

error dependencia cola

#1

8,468 %

MAE test con +25 %

vs 7,955 % real-only


Fortaleza Preserva dependencia conjunta y extremos.

Límite No mejora el test downstream.

● El baseline domina varias métricas, pero no la utilidad downstream.

Normalizing Flow

Densidad exacta para puntuar escenarios y estudiar colas bajo el modelo.



CHECKPOINT

Época 5

NLL val/dim = 0,798

0,049

persistencia volatilidad
#1

0,162

W1 maximum drawdown
#1

0,126

cobertura VaR 95 %
mejor error

0,124


cobertura VaR 99 %
mejor error

Downstream Validación mantiene real-only. El +100 % mejora test un 4,3 %, pero solo de forma descriptiva.

● La NLL detecta el overfitting: el mejor checkpoint llega muy pronto, antes de que validación se dispare.

Conditional GAN

La elegimos para contrastar un aprendizaje adversarial flexible con CVAE y Flow.



ÉPOCA 70

0,518

error corr. en estrés
peor modelo

100 %

discriminador externo
perfectamente separable

0,950

cobertura referencia
#1

7,052 %

MAE test con +100 %
-11,4 % descriptivo


Score val. = 0,652

Checkpoint seleccionado sin test +100 % es descriptivo

● Mensaje clave del taller: fidelidad generativa ≠ utilidad downstream.

CVAE condicional

Lo elegimos para modelar múltiples futuros condicionados mediante un espacio latente probabilístico.



74,5 %

discriminador externo
mejor de los neurales

0,139

distancia de regímenes
#1

0,316

W1 volatilidad realizada
#1

7,770 %

MAE test con +25 %
vs 7,955 % real-only



Entrenamiento: 18 épocas

Early stopping con `val_total_loss` · test no interviene

● CVAE es el modelo más “equilibrado”: no domina todo, pero es el más difícil de separar de los datos reales.

No hay un ganador global

Cada modelo domina una dimensión distinta; el objetivo financiero determina cuál es “mejor”.



BOOTSTRAP
dependencia + colas

CVAE
regímenes + realismo

FLOW
temporal + VaR/DD

GAN
coverage + señal downstream

● **Conclusión defendible: comparar generadores exige separar fidelidad, riesgo y utilidad predictiva; sumar todo en un único score ocultaría trade-offs reales.**